

Kristjan Sešek  
Vpisna številka: 63110315  
Brodka cesta 24, 1000 Ljubljana  
Slovenija

**Komisija za študijske zadeve**

Univerza v Ljubljani, Fakulteta za računalništvo in informatiko  
Večna pot 113, 1000 Ljubljana

## **Vloga za prijavo teme magistrskega dela**

**Kandidat: Kristjan Sešek**

Podpisani/-a študent/-ka magistrskega programa na Fakulteti za računalništvo in informatiko, zaprošam Komisijo za študijske zadeve, da odobri temo dela, podrobno opisanega v nadaljnjem predlogu teme magistrskega dela.

Okvirni naslov magistrskega dela:

slovensko: **Napovedovanje porabe električne energije z uporabo globokih nevronske mreže**

angleško: **Electricity consumption forecasting using deep neural networks**

Ime in priimek, naziv: izr. prof. dr. Marko Robnik Šikonja

Ustanova: Fakulteta za računalništvo in informatiko

Elektronski naslov: marko.robniksikonja@fri.uni-lj.si

Komisijo zaprošam, da odobri pisanje magistrskega dela v angleškem jeziku, saj bom v drugem semestru v sklopu programa Erasmus na Češkem v Brnu, kjer bom delal in pisal magistrsko delo.

V Ljubljani, dne 4.12.2017

Podpis mentorja:

Podpis kandidata/kandidatke:

# PREDLOG TEME MAGISTRSKEGA DELA

## 1 Področje magistrskega dela

slovensko: strojno učenje

angleško: machine learning

## 2 Ključne besede

slovensko: strojno učenje, globoke nevronske mreže, časovne vrste, napovedovanje porabe električne energije

angleško: machine learning, deep neural networks, time series, electricity consumption forecasting

## 3 Opis teme magistrskega dela

### 3.1 Uvod in opis problema

Časovne vrste so množice časovno označenih podatkov. Časovne vrste najdemo v vseh industrijskih panogah in dobro napovedovanje in modeliranje časovnih vrst je ključnega pomena za boljše odločanje. V magistrski nalogi se bom osredotočil na časovno vrsto porabe električne energije. V tem primeru boljša napoved porabe električne energije neposredno vpliva na boljšo razporeditev električne energije po omrežju in nižje stroške.

Osnovni modeli za napoved porabe električne energije so dobro opisani v mnogih delih, denimo [1]. V magistrski nalogi bom nadgradil osnovne modele nevronske mreže za napovedovanje porabe električne energije z metodami globokih nevronske mreže.

### 3.2 Pregled sorodnih del

V diplomski nalogi Jana Kraljiča [1] je primerjava več modelov za napovedovanje časovnih vrst za porabo električne energije. V zaključku izvemo, da je najbolje uporabiti algoritem naključnih gozdov. V diplomski nalogi je kot primer nevronske mreže vzeta osnovni model iz modula R nnet [2]. Glede na velik napredek na področju nevronske mreže je zelo verjetno, da bi izboljšana in naprednejša nevronska mreža prinesla boljše rezultate.

Goodfellow, Bengio in Courville [3] predstavijo uvod v strojno učenje in se osredotočijo na poglobljeno delovanje nevronske mreže. Delo ne omenja uporabe nevronske mreže za napovedovanje časovnih vrst, vendar je pomembno za razumevanje delovanja nevronske mreže.

Gamboa [4] je analiziral konvolucijsko in rekurenčno nevronske mreže za napovedovanje splošnih časovnih vrst in opisal njune prednosti in slabosti. Opisane so tudi naloge, ki jih lahko rešujemo z uporabo nevronske mreže pri časovnih vrstah.

Kourentzes, Barrow in Crone [5] so analizirali uporabo ansamblorov nevronske mreže za napovedovanje časovnih vrst. Iz članka izvemo, kako deluje in kako uporabiti ansambelski operator povprečja in mediane.

Gajowniczek in Zabkowski [6] raziskujeta problem kratkoročnega napovedovanja porabe električne energije na nivoju posameznikov. Izhajala sta iz dejstva, da je kratkoročno napovedovanje nestabilno in zato neprimerno za modeliranje z regresijo in ARIMA modeli. Namesto tega uporabita nevronske mreže, ki imata lastnost, da najde skrite trende, ki jih ostali modeli ne najdejo. Opišeta strukturo nevronske mreže in uporabljene attribute, ki so pomembni za napovedovanje porabe električne energije.

Ringwood, Bofelli in Murray [7] raziskujejo uporabo nevronske mreže za napovedovanje porabe električne energije za naslednji dan, naslednji teden in naslednje leto. Za naš primer je pomembna samo napoved za naslednji dan. Pri uporabi nevronske mreže opozorijo na problem izbire arhitekture nevronske mreže in razložijo, kako so ta problem rešili.

### **3.3 Predvideni prispevki magistrske naloge**

Rezultat magistrske naloge bo analiza in implementacija napovedovanja časovnih vrst z uporabo nevronske mreže. Prispevek magistrske naloge je uporaba globokih nevronske mreže za napovedovanje časovnih vrst porabe električne energije. Združil bom več različnih obstoječih metod in jih posamično in v ansamblu primerjal z novo predlaganimi metodami. Predvidevamo napredek glede na do sedaj dosežene rezultate, analizirane v [1].

### 3.4 Metodologija

V magistrski nalogi bom najprej zgradil nekaj osnovnih modelov za napovedovanje časovnih vrst, ki jih bom nadgradil z metodami globokega učenja. Uporabil bom usmerjeno konvolucijsko in LSTM rekurenčno nevronske mrežo. Podatki so zbrani s 15 minutnimi zamiki nad množico tisoč merilnih mest in v obdobju dveh let. Podatki niso javno dostopni. Za zagotovitev ponovljivosti rezultatov in možnosti nadaljnega raziskovanja bom uporabil tudi podobno javno dostopno zbirko podatkov [8]. Poraba električne energije se močno razlikuje v različnih časovnih obdobjih in v različnih vremenskih razmerah. Glavni atributi bodo podatki porabe, vremenski podatki in izvlečeni podatki iz časovnega žiga. V grobem so to čas v dnevu, dan v tednu, vikend ali praznik, mesec in sezona. Napovedovati nameravam porabo do 2 dni vnaprej. Zgrajene modele bom primerjal z najboljšim modelom, ki je bil uporabljen [1]. Rezultate bom analiziral in analize uporabil za izboljšave.

### 3.5 Literatura in viri

- [1] J. Kraljič, Forecasting the electricity consumption data stream, Diplomsko delo, Fakulteta za računalništvo in informatiko, 2011.  
URL <http://eprints.fri.uni-lj.si/1375/>
- [2] B. Ripley, W. Venables, Feed-forward neural networks and multinomial log-linear models [dostopano 5.12.2017], <https://cran.r-project.org/web/packages/nnet/nnet.pdf> (2016).
- [3] I. Goodfellow, Y. Bengio, A. Courville, Deep Learning, MIT Press, 2016, <http://www.deeplearningbook.org>.
- [4] J. C. B. Gamboa, Deep learning for time-series analysis, CoRR abs/1701.01887. arXiv:1701.01887.
- [5] N. Kourentzes, D. K. Barrow, S. F. Crone, Neural network ensemble operators for time series forecasting, Expert Systems with Applications 41 (9) (2014) 4235 – 4244.
- [6] K. Gajowniczek, T. Ząbkowski, Short term electricity forecasting using individual smart meter data, Procedia Computer Science 35 (Supplement C) (2014) 589 – 597, knowledge-Based and Intelligent Information Engineering Systems 18th Annual Conference, KES-2014 Gdynia, Poland, September 2014.
- [7] J. V. Ringwood, D. Bofelli, F. T. Murray, Forecasting electricity demand on short, medium and long time scales using neural networks, Journal of Intelligent and Robotic Systems 31 (1) (2001) 129–147.

- [8] U. P. Networks, Smartmeter energy consumption data in households [dostopano 6.1.2017], <https://data.london.gov.uk/dataset/smartmeter-energy-use-data-in-london-households>.

Ljubljana, 13. maj 2018.